

Análisis Matemático

Clase 3

Autovalores y autovectores

Motivación

La idea de descomponer en autovalores (**avas**) y autovectores (**aves**), es poder recuperar propiedades "universales" de la matriz.

Por ejemplo, la descomposición de un número en números primos. No importa como represente el número 12 (en que base) siempre vale que $12 = 2 \times 3 \times 3$, y se pueden extraer propiedades

Definición

Def: Sea $A \in \mathbb{C}^{n \times n}$, diremos que $\lambda \in \mathbb{C}$ es un **autovalor** de A y $x \in \mathbb{C}^n$ es el **autovector** asociado a λ si

$$Ax = \lambda x$$

Interpretación geométrica: A cada vector que se encuentre en la dirección de x , la transformación $T(x) = Ax$ lo contrae (o expande) por un factor λ

Algunas aplicaciones

- Análisis de estabilidad de sistemas de control
- Análisis de estabilidad en ing. mecánica y civil
- Criptografía (cifrado de Hill)
- Cálculo de resonancias del sistema
- Clustering espectral
- PCA
- PageRank

¿Cómo encuentro los autovalores?

Teorema: Dada $A \in \mathbb{C}^{n \times n}$, λ es un autovalor de A sii. λ es un cero del polinomio característico de A :

$$p(\lambda) := \det(A - \lambda I)$$

Obs: Puede ocurrir que algún λ sea raíz múltiple de $p(\lambda)$. Se llama **multiplicidad algebraica** (m_A), a la cantidad de veces que λ aparece como raíz.

¿Hay alguna forma más fácil?

¡Si! En python:

```
1 | s, V = np.linalg.eig(A)
```

s: es el vector de autovalores, ordenados de mayor a menor ($\lambda_1 \geq \dots \geq \lambda_n$)

V: Son los autovectores asociados a cada λ_i , escalados para que tengan norma 1.

Propiedades de los autovectores

Def: Dada $A \in \mathbb{R}^{n \times n}$, el conjunto de todos los autovectores asociados al autovalor λ generan un subespacio de \mathbb{R}^n (**autoespacio** de A respecto de λ). El conjunto de todos los autovectores de A se llama **autoespectro**.

Si λ es un autovalor de $A \in \mathbb{R}^{n \times n}$, el autoespacio E_λ asociado es la solución al sistema homogéneo $(A - \lambda I)x = 0$.

Más propiedades de los autovectores


Def: Se llama **multiplicidad geométrica** (m_g) del autovalor λ a la cantidad de autovectores l.i. asociados a λ . **Obs:** $1 \leq m_g \leq m_a$.

Teorema: Los autovectores $x_1 \dots x_n$ de una matriz $A \in \mathbb{R}^{n \times n}$ con n autovalores distintos $\lambda_1, \dots, \lambda_n$ son l.i. (i.e. forman una base de \mathbb{R}^n)

Teorema: Si $A \in \mathbb{R}^{n \times n}$ es simétrica, entonces existe una base ortonormal correspondiente a un espacio V , formado por autovectores de A , todos los $\lambda_i \in \mathbb{R}$


Propiedades asociadas

Teorema: $\det(A) = \prod_i \lambda_i$. (área)





Teorema: $\text{Tr}(A) = \sum_i \lambda_i$ (perímetro)



Interpretación gráfica





$\lambda_1 = 2.0$
 $\lambda_2 = 0.5$
 $\det(\mathbf{A}) = 1.0$





$\lambda_1 = 0.0$
 $\lambda_2 = 2.0$
 $\det(\mathbf{A}) = 0.0$




$\lambda_1 = 1.0$
 $\lambda_2 = 1.0$
 $\det(\mathbf{A}) = 1.0$



$\lambda_1 = 0.5$
 $\lambda_2 = 1.5$
 $\det(\mathbf{A}) = 0.75$



$\lambda_1 = (0.87-0.5j)$
 $\lambda_2 = (0.87+0.5j)$
 $\det(\mathbf{A}) = 1.0$



Diagonalización de una matriz

Def: Una matriz $A \in \mathbb{C}^{n \times n}$ es **digonalizable** si es similar a una matriz diagonal D . Es decir si existe $Q \in \mathbb{C}^{n \times n}$ invertible tal que $D = Q^{-1}AP$

Teorema: Una matriz cuadrada $A \in \mathbb{C}^{n \times n}$ puede ser factorizada como

$$A = QDQ^{-1},$$


con $Q \in \mathbb{C}^{n \times n}$ y D diagonal tal que $D_{ii} = \lambda_i$, **sii.** los autovectores de A forman una base de $\mathbb{C}^{n \times n}$.

Diagonalización (continuación)

Obs 1: las columnas de Q se van a corresponder con los autovectores de A .

Obs 2: Toda matriz hermítica puede ser diagonalizable.

Obs 3: Más aún, si A es hermítica, las columnas forman un BON y

$$A = Q^T D Q$$


Descomposición en valores singulares

¿Qué pasa si las matrices no son cuadradas?

Teorema: Dada $A \in \mathbb{C}^{m \times n}$, siempre se puede obtener una matriz hermítica, semidefinida positiva $S \in \mathbb{C}^{n \times n}$ como:

$$S := A^H A$$

Obs: $\tilde{S} \in \mathbb{C}^{m \times m}$ definida como $\tilde{S} := A A^H$ también resulta hermítica y semidefinida positiva

Descomposición en valores singulares

Teorema: Sea $A \in \mathbb{C}^{m \times n}$ una matriz rectangular de rango $r \in [0, \min(m, n)]$. La **descomposición en valores singulares** (SVD) de A es una descomposición de la forma:

$$\begin{array}{c} n \\ \boxed{A} \\ m \end{array} = \begin{array}{c} m \\ \boxed{U} \\ m \end{array} \begin{array}{c} n \\ \boxed{\Sigma} \\ m \end{array} \begin{array}{c} n \\ \boxed{V^T} \\ n \end{array}$$

Descomposición en valores singulares (continuación)

donde $U \in \mathbb{C}^{m \times m}$ es la matriz ortogonal con columnas u_i , $i = 1, \dots, m$, $V \in \mathbb{C}^{n \times n}$ con columnas v_i , $i = 1, \dots, n$, y $\Sigma \in \mathbb{C}^{m \times n}$ es una matriz "diagonal" ($\Sigma_{ii} = \sigma_i \geq 0$, y $\Sigma_{ij} = 0, i \neq j$)

Las columnas de U son los autovectores de AA^H

Las columnas de V son los autovectores de $A^H A$

$\sigma_i = \sqrt{\lambda_i}$, y λ_i son los autovalores distintos de cero de $A^H A$ y AA^H .

SVD Truncada

Sea $A \in \mathbb{C}^{m \times n}$

- Si $m > n$, A se puede descomponer como

$$A = U_m \Sigma_m V_m^T$$


- Si $m < n$ A se puede descomponer como

$$A = U_n \Sigma_n V_n^T$$

- En general, si A tiene r autovalores distintos de cero vale que

$$A = U_r \Sigma_r V_r^T$$

SVD Truncada



Python

Para calcular la SVD:

```
1 | U,s,Vt = np.linalg.svd(A)
```

donde $U \in \mathbb{C}^{m \times m}$, $s = [\sigma_1, \dots, \sigma_r]$, $V \in \mathbb{C}^{n \times n}$.

```
1 | U,s,Vt = np.linalg.svd(A,full_matrices=False)
```

devuelve la SVD reducida.

Pseudoinversa de Moore-Penrose

Sean $A \in \mathbb{C}^{m \times n}$, y el sistema lineal $Ax = y$. La inversa de A no está definida, pero habíamos visto que una posible solución era

$$\hat{x} = (A^T A)^{-1} A^T y.$$

¿Qué ocurre si $(A^T A)$ no es invertible? Se define la **pseudoinversa de Moore-Penrose** como $A^\dagger = V_r \Sigma_r^{-1} U_r^T$

y $\hat{x} = A^\dagger y$ es la solución de norma mínima (euclídea) ($m > n$), o la solución de mínimo error (distancia euclídea) ($m < n$).

Para calcular la pseudoinversa

```
1 | Ainv = np.linalg.pinv(A)
```

Bibliografía

Bibliografía

- Mathematics for Machine Learning
- Eigenvalues and Eigenvectors